

1. Momentum

개념

Momentum은 경사하강법(Gradient Descent)의 수렴 속도를 높이고 진동을 줄이기 위해 제안된 옵티마이저이다.

기존의 **SGD**는 현재 기울기(**gradient**)만을 기준으로 가중치를 업데이트하기 때문에, 좁고 깊은 손실 함수의 골짜기에서 좌우로 흔들리며 느리게 수렴하는 경향이 있다.

Momentum은 이전 단계의 기울기 방향을 일정 비율로 유지해 관성 효과를 주어, 더 안정적이고 빠른 수렴을 가능하게 한다.

해결하고자 한 문제

- 기본 **SGD**의 진동 및 느린 수렴 문제

적용 아이디어

- 물리학의 '관성(momentum)' 개념을 적용
- 이전 업데이트 방향을 일정 비율로 유지하면서 새로운 기울기를 더함

2. Adagrad

개념

Adagrad는 'Adaptive Gradient'의 약자로, 각 파라미터마다 학습률을 다르게 적용하는 옵티마이저이다.

자주 업데이트되는 파라미터의 학습률은 점점 감소시키고, 드물게 업데이트되는 파라미터의 학습률은 증가시켜, 희소(**sparse**) 데이터에서도 효율적인 학습을 가능하게 한다.

해결하고자 한 문제

- 모든 파라미터에 동일한 학습률을 적용하는 비효율성
- 희소 데이터에서의 학습 성능 저하

적용 아이디어

- 각 파라미터별로 기울기의 제곱 누적합을 계산하여 학습률을 자동으로 조정함

3. RMSProp

개념

RMSProp은 Adagrad의 한계를 개선하기 위해 제안된 옵티마이저이다.

Adagrad는 과거 기울기의 제곱을 계속 누적하다 보니 학습률이 점차 0에 가까워지는 문제가 있었다.

RMSProp은 기울기 제곱의 평균을 지수이동평균(EMA, Exponential Moving Average)으로 계산하여, 최근 기울기에 더 큰 비중을 두고 학습률이 일정 수준으로 유지되도록 한다.

해결하고자 한 문제

- Adagrad의 학습률 감소 문제

적용 아이디어

- 기울기 제곱의 누적합 대신 지수이동평균을 사용하여 안정적인 학습률 유지

4. Adam (Adaptive Moment Estimation)

개념

Adam은 Momentum과 RMSProp의 장점을 결합한 옵티마이저로, 현재 가장 널리 사용되는 방식 중 하나이다.

기울기의 평균(1차 모멘트)과 제곱평균(2차 모멘트)을 함께 추적하여, 학습률을 자동 조정하면서도 빠르고 안정적인 학습을 수행할 수 있다.

해결하고자 한 문제

- 빠른 수렴 속도와 안정적인 학습을 동시에 달성

적용 아이디어

- Momentum의 '속도' 개념과 RMSProp의 '적응적 학습률' 개념을 결합
- 초반 단계에서 발생하는 편향을 줄이기 위해 편향 보정(bias correction)을 추가

5. AdamW

개념

AdamW는 Adam 옵티마이저의 정규화(L2 Regularization) 문제를 개선한 버전이다.

기존 Adam은 정규화 항(Weight Decay)을 기울기 계산에 포함시켜, 정규화 효과가

왜곡되는 문제가 있었다.

AdamW는 이 항을 기울기 업데이트와 분리하여 적용함으로써, 과적합을 방지하고 일반화 성능을 향상시켰다.

해결하고자 한 문제

- **Adam**에서 **Weight Decay**가 제대로 작동하지 않아 과적합 방지 효과가 약했던 문제

적용 아이디어

- **Weight Decay**를 별도의 항으로 분리 적용
- 학습 안정성을 유지하면서 일반화 성능을 개선

이 다섯 가지 옵티마이저는 모두 기본 경사하강법(**SGD**)의 한계를 해결하기 위해 발전해 온 방법들이다.

Momentum은 진동 문제를, **Adagrad**는 파라미터별 학습률 조정을, **RMSProp**은 학습률 안정성을,

Adam은 빠르고 안정적인 학습을, **AdamW**는 올바른 정규화를 목표로 한다.

현재는 **AdamW**가 가장 표준적으로 사용되고 있으며, 다양한 딥러닝 모델에서 기본 설정으로 채택되고 있다.