

5-1 결정 트리 (Decision Tree)

핵심 개념

데이터를 Yes/No 질문으로 반복 분할하는 알고리즘

분류(Classification)와 회귀(Regression) 모두 가능

트리는 사람이 이해하기 쉬워 시각화 가능하지만, 깊을수록 과대적합 위험 증가

용어 정리

노드(node): 데이터를 나누는 기준

루트 노드(root): 트리의 시작점

리프 노드(leaf): 최종 분류 결과를 나타내는 끝점

지니 불순도(Gini impurity): 노드의 순수도 측정. 0에 가까울수록 한쪽 클래스만 존재

정보 이득(Information Gain): 분할 전후의 불순도 감소량

주요 개념 코드

Python

```
from sklearn.tree import DecisionTreeClassifier
dt = DecisionTreeClassifier(random_state=42)
dt.fit(train_scaled, train_target)
```

코드 복사

결과

- 훈련 정확도: 0.9969
- 테스트 정확도: 0.8592 → 과적합
- 가지치기(max_depth=3) → 훈련 0.845, 테스트 0.841
- 특성 중요도: **sugar(0.869)** > alcohol > pH

요약

결정 트리는 직관적이고 해석이 쉽지만, 깊어질수록 과대적합되므로 가지치기로 조정해야 한다.

5-2 교차 검증과 그리드 서치

핵심 개념

모델의 신뢰성과 일반화 성능을 높이기 위해 데이터를 반복 검증함.

단일 검증 세트보다 교차 검증(cross-validation) 을 사용하면 데이터 낭비 없이 안정적인 성능 평가 가능.

1 교차 검증

데이터를 여러 부분으로 나누어 각 부분을 번갈아 검증 세트로 사용

k-폴드 교차 검증: k개의 폴드로 나누어 평균 점수를 계산

StratifiedKFold: 분류 문제에서 클래스 비율을 동일하게 유지

2 하이퍼파라미터 튜닝

모델이 스스로 학습하지 못하는 설정값(max_depth, min_samples_split 등)을 최적화

GridSearchCV: 가능한 모든 조합을 시험

RandomizedSearchCV: 일부 무작위 조합만 시험 (빠름)

예시 코드

Python

```
from sklearn.model_selection import GridSearchCV
params = {'min_impurity_decrease': [0.0001, 0.0002, 0.0003]}
gs = GridSearchCV(DecisionTreeClassifier(random_state=42), params, n_jobs=-1)
gs.fit(train_input, train_target)
print(gs.best_params_, gs.best_score_)
```

결과

- min_impurity_decrease = 0.0001 → 평균 점수 약 **0.867**
- 랜덤 서치(RandomizedSearchCV):
{max_depth: 39, min_impurity_decrease: 0.00034} → 테스트 점수 **0.86**

요약

교차 검증은 모델 평가의 신뢰도를 높이고,
그리드/랜덤 서치는 자동으로 최적의 하이퍼파라미터를 찾아준다.

5-3 트리의 앙상블 (Tree Ensemble)

핵심 개념

앙상블 학습: 여러 모델을 조합해 단일 모델보다 높은 성능을 내는 방법

트리 기반 앙상블은 정형 데이터(표 형태 데이터)에 특히 강함

—

1 랜덤 포레스트 (Random Forest)

여러 결정 트리를 랜덤한 데이터 샘플로 학습시킨 후 평균/다수결로 결과 결정

과대적합 줄이고 안정적인 성능 제공

테스트 점수: 0.88

—

2 엑스트라 트리 (Extra Trees)

랜덤 포레스트와 유사하지만

부트스트랩 샘플 사용 X

분할 기준도 무작위 선택

속도가 빠르고 과적합 위험이 낮음

테스트 점수: 0.89

—

3 그래디언트 부스팅 (Gradient Boosting)

이전 트리의 오차를 보완하는 트리를 순차적으로 추가

과대적합 억제, 높은 일반화 성능

테스트 점수: 0.87

4 히스토그램 기반 그래디언트 부스팅 (HistGradientBoosting)

데이터를 256개 구간으로 나누어 학습 속도 극대화

기존 부스팅보다 빠르고 안정적

테스트 점수: 0.88

5 XGBoost / LightGBM

XGBoost: 고성능 오픈소스 부스팅 알고리즘

훈련 점수 0.955 / 테스트 0.878

LightGBM: Microsoft 개발 최신 부스팅 알고리즘

속도 빠르고 대규모 데이터에 효율적

테스트 점수 0.880

⚙️ 앙상블 모델 비교

모델	장점	단점	테스트 정확도
랜덤 포레스트	안정적, 과대적합 적음	계산량 많음	0.88
엑스트라 트리	빠름, 단순	정확도 약간 낮을 수 있음	0.89
그래디언트 부스팅	높은 정확도	속도 느림	0.87
히스토그램 기반 부스팅	매우 빠름, 효율적	복잡함	0.88
XGBoost	최고 성능, 강력	설정 복잡	0.878
LightGBM	빠르고 효율적	세부 튜닝 필요	0.880

전체 핵심 포인트 요약

1. 결정 트리는 해석이 쉽지만 과대적합되기 쉬움 → 깊이 조절 필요
2. 교차 검증은 데이터 낭비 없이 모델 신뢰성 향상
3. 그리드 서치/랜덤 서치로 최적 파라미터 자동 탐색
4. 앙상블 학습은 여러 트리를 결합하여 정확도와 안정성 향상
5. 랜덤 포레스트·엑스트라 트리는 빠르고 안정적
6. 부스팅 계열(XGBoost, LightGBM)은 가장 높은 성능을 제공